[머신러닝 및 딥러닝] 실습 #3 : Clustering — 고객 Segmentation

데이터 Wholesale Customers (UCI id=292) 440명 × 8변수 · **노트북** `실습_Clustering.ipynb`

(1) 개별 실험

① 주요 설정값

항목	값
입력 / 제외	지출 6개 사용 · **Channel·Region 제외** (묶는 데 안 쓰고 결과 **검증용**으로만)
전처리	`log1p` → `StandardScaler`
최종 모델	`KMeans(n_clusters=4, n_init=10, random_state=42)`

② 전처리 — 로그 변환 (Q2)

지출 최대값이 중앙값의 **13~50배**(Delicassen 왜도 11.2)라, 원척도로 거리를 재면 **큰손 몇 명이 거리를 독점**한다.

설정	Silhouette	군집 크기
원척도 k=2	0.547	**[389, 51]** — 88% 쏠림
원척도 k=3	0.548	[393, 45, **2**] — **2명짜리 군집**
로그 k=4 (채택)	0.188	[132, 129, 118, 61]

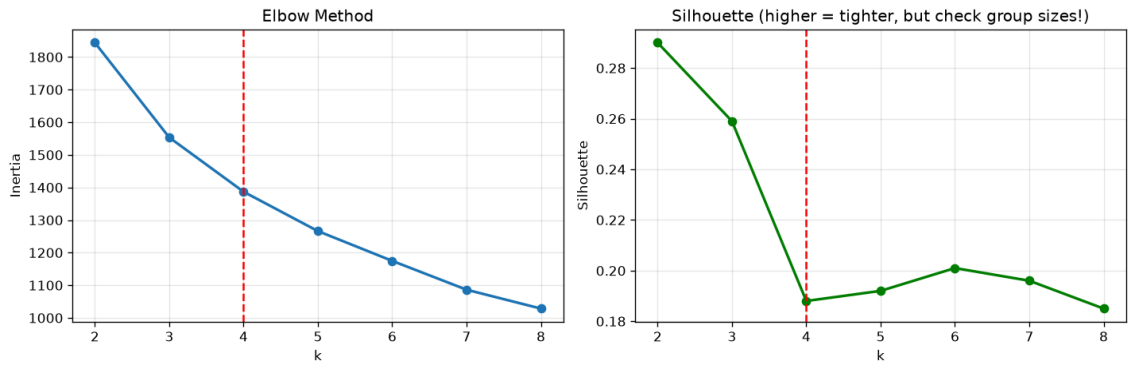
> **원척도를 배제한 근거는 점수가 아니라 군집 크기다.** 실루엣은 *주어진 좌표 공간*에서 계산되므로 0.548(원척도 공간)과 0.188(로그 공간)은 **서로 다른 시험의 점수**라 직접 비교할 수 없다. 반면 `[389, 51]` · `[393, 45, 2]` 는 어느 공간에서 재든 세분화가 아니다. (상세: §(2)-2)

③ Cluster 수 결정 (Q2)

k	Silhouette	CH	Dunn	안정성	Channel 일치도
2	**0.290**	**189.1**	0.066	0.965	**0.514** ← Channel 재발견
3	0.259	152.8	0.042	0.968	0.350
4 (채택)	0.188	131.3	0.033	0.848	0.280
5	0.192	118.0	0.033	**0.760**	0.212
6	0.201	108.3	**0.055**	0.697	0.194

- **세 지표가 서로 다른 k 를 가리킨다** (Silhouette·CH → k=2, Dunn → k=6) → 지표 하나로는 못 정한다
- **안정성**(데이터 90%로 재군집화 시 일치도)은 단조 감소, **k=5 부터 0.76 이하**
- **k=2 는 Channel 일치도 0.514** — '식당 vs 소매점' 이라는 **이미 아는 정보**의 재발견

지표로는 k=3 이 낫다(Silhouette 0.259, 안정성 0.968). 그럼에도 **k=4** 를 택한 이유는 **k=3 의 213명 군집이 두 집단의 혼합**이기 때문이다 — 식당(Fresh 2.00배·Frozen 2.83배) 84명과 소규모(0.92·0.91배) 129명이 섞여 평균 1.1·1.4배로 보인다. **마케팅 액션이 다르므로 분리했다.**



[그림 1] Elbow(좌)와 Silhouette(우) — 두 지표가 서로 다른 k 를 가리킨다

④ Method 비교 — k=4, 동일 공간에서 측정 (Q1, Q3)

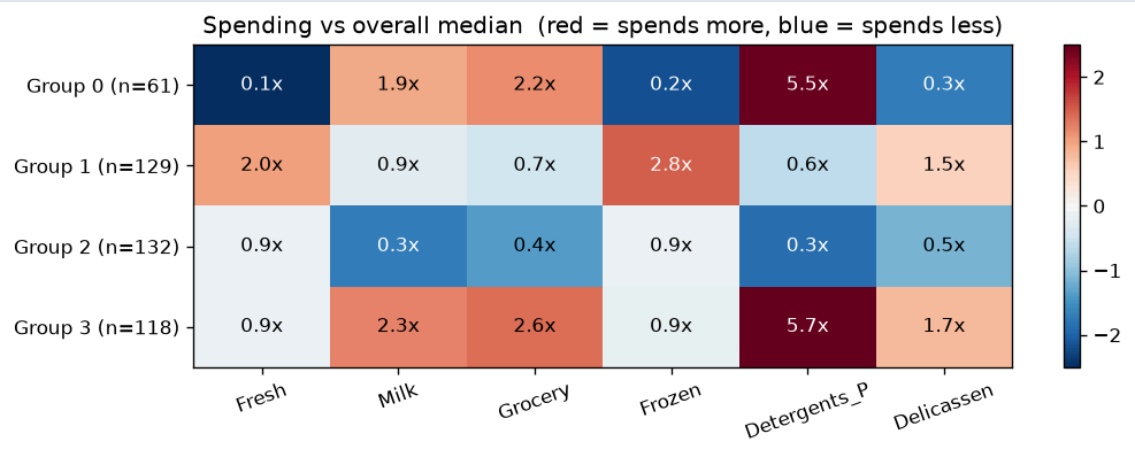
방법	Silhouette	CH	Dunn	군집 크기
Hierarchical **average** · **single**	**0.498**	8.4	**0.336**	**[437, 1, 1, 1]** ✗
Hierarchical complete	0.260	38.9	0.096	[391, 33, 11, 5] ✗
Hierarchical ward	0.202	108.6	0.055	[208, 125, 54, 53] △
K-Means (채택)	0.188	**131.3**	0.033	**[132, 129, 118, 61]** ✓

같은 공간에서 잰 비교라 유효하다. 그리고 세 지표 중 둘(Silhouette·Dunn)이 [437, 1, 1, 1] 에 1위를 준다. 440명 중 437명을 한 덩어리로 묶고 3명을 떼어낸 결과다. 유용성과 같은 방향인 것은 **CH 뿐**이다. → **Q3 의 답: 지표가 가장 좋은 모델이 가장 해석하기 좋은 Segmentation은 아니다.**

- **DBSCAN 은 실패** — eps 0.8~2.5 어디서도 *"군집 1개"* 아니면 *"노이즈 52%"*. 로그변환 후 이 데이터는 밀도 골짜기가 없는 하나의 덩어리다. 반면 베이스 코드의 **Moon 데이터에서는 DBSCAN 이 유일하게 정답**이었다 (그때 Silhouette 은 DBSCAN 0.376 으로 **꼴찌**, Dunn 은 0.109 로 1위). → **Q1 의 답: 데이터 형태가 방법을 정한다. 그리고 어떤 지표도 항상 맞지 않는다** (Moon 에선 Dunn 이 맞고 Silhouette 이 틀렸는데, 실제 데이터에선 Dunn 마저 틀렸다).
- K-Means 와 ward 는 점수가 비슷한데 **ARI 0.40** → 누가 어느 군집인지는 다르다

⑤ Customer Profiling (Q4) — 전체 중앙값 대비 배수 (1.0 = 평균 고객)

	인원	Fresh	Milk	Grocery	Frozen	Deterg.	Delica.	소매%	고객 특성 → **업무 활용**
C0	61 (14%)	**0.13**	1.92	2.21	**0.22**	**5.52**	0.31	66%	생활용품 소매 · **콜드체인 없음** → 상온 상품만 제안, 냉동 프로모션 제외
C1	129 (29%)	**2.00**	0.85	0.72	**2.83**	0.65	1.45	5%	식당·외식업 → **정기 배송·새벽 납품**, 식자재 번들
C2	132 (30%)	0.92	**0.31**	**0.38**	0.91	**0.27**	0.45	1%	소규모·저활동 → **재구매 유도**, 이탈 위험군 관리
C3	118 (27%)	0.92	**2.34**	**2.58**	0.88	**5.69**	1.74	80%	대형 슈퍼마켓 → **전담 관리·단가 협상**



[그림 2] 클러스터 프로파일 — 전체 중앙값 대비 배수 (빨강=많이 씀, 파랑=적게 씀)

외부 검증(입력에 넣지 않은 변수) — Channel 일치도 **0.280**: Horeca→C1/C2, Retail→C0/C3 로 갈린다. 즉 **Channel 구조를 담되 그 안을 한 번 더 쪼갰다.** Region 일치도 **−0.006** → **지역은 소비 패턴과 무관.** 지역이 아니라 **업태·규모** 기준으로 관리해야 한다.

(2) 조별 토의

1) 결과가 갈린 진짜 원인은 알고리즘이 아니라 전처리였다

조 인원은 5명이며, 아래는 **설정과 결과를 직접 대조할 수 있었던 3명**의 비교다.

	전처리	k	군집 크기
조원 A	지출 6개 **표준화만**	2	[252, 188]
본인	지출 6개 **로그 + 표준화**	4	[132, 129, 118, 61]
조원 B	지출 6개 + **Channel·Region 원-핫** + 표준화	13	1~3명짜리 군집 다수

`Elbow` 의 **k=1 inertia 로 서로의 전처리를 역추적**할 수 있었다. 표준화하면 분산이 1이므로 k=1 inertia 는 정확히 `표본수 × 변수수` 다. 조원 A 그래프의 **2,640 = 440 × 6** → 지출 6개만 사용, 조원 B 의 ≈3,000 → **원-핫 열이 추가**된 것. 같은 데이터·같은 알고리즘인데 **어느 공간에 올려놓았는지**가 갈랐다.

2) 서로 다른 공간의 점수는 직접 비교할 수 없다 ← 토의의 최대 소득

본인은 처음에 *"원척도 0.548 vs 로그 0.188"*을 나란히 놓고 *"점수 1위가 가장 쓸모없다"*고 정리했으나 **잘못된 비교**라는 지적을 받았다. 공간을 맞춰 다시 재면 순위가 바뀐다.

어느 공간에서 재나	원척도 k=2 라벨	로그 k=4 라벨
둘 다 로그 공간	0.231	0.188
둘 다 원척도 공간	0.547	0.038

→ 원척도 배제 근거를 **점수 → 군집 크기**로 정정했고, *"지표가 배신한다"*는 주장은 **같은 공간에서 잰 §(1)-④** 에서만 유효하다.

3) 해석은 사실 크게 다르지 않았다 — 조원 A k=2 의 군집0(252명, Channel 1 이 244명)=외식업, 군집1(188명, Channel 2 가 134명)=소매. 본인 k=4 는 그 둘을 각각 한 번 더 쪼갠 것에 가깝다. 구매 패턴의 큰 방향은 **일치**했고, 차이는 *"어디까지 나눌 것인가"*였다.

4) 선정 기준 자체가 달랐다 — 조원 A는 *분리가 잘 보이는가*, 본인은 *운영 가능한 크기 + 특성 구별*, 조원 B 는 *지표와 특성을 함께.* 다만 **군집 크기가 고르다는 사실만으로 좋은 군집은 아니다**(실제 고객 구조가 불균형할 수도 있다). 그래서 본인의 선정 이유는 이렇게 쓰는 것이 정확하다 — *"원척도 모델은 대다수가 한 군집에 몰리거나 극소수 군집이 생겼다. 로그 모델은 점수가 낮더라도 운영 가능한 크기의 집단과 서로 구분되는 구매 특성을 제공하여 선택했다."*

(3) 개인 시사점

1. **"점수가 높다/낮다"를 말하려면 같은 조건에서 잰 것이어야 한다.** 원척도 0.548 과 로그 0.188 을 나란히 놓고 결론을 냈는데 두 값은 **서로 다른 좌표 공간**의 점수라 비교가 성립하지 않았다. 토의에서 지적받고 알았다. **숫자를 비교하기 전에 "같은 시험을 본 것인가"를 확인해야 한다.**
2. **그럼에도 "지표가 목적이 될 수 없다"는 결론은 유지된다.** 같은 공간에서 잰 §(1)-④ 에서 Silhouette 1위(0.498)와 Dunn 1위(0.336)가 모두 **[437, 1, 1, 1]** 이었다. 군집화에서는 **점수를 올리는 가장 쉬운 방법이 이상치를 떼어내는 것**이다.
3. **결과 차이의 원인은 알고리즘이 아니라 전처리였다.** 확인된 세 명의 k 가 2/4/13 으로 갈린 원인은 K-Means 냐 Hierarchical 이냐가 아니라 **로그를 씌웠는가, 원-핫을 넣었는가** 였다. `Elbow` 의 k=1 inertia 로 서로의 전처리를 역추적할 수 있었던 것이 가장 인상적이었다.